

Detección de ondas gravitacionales

C. Quijas¹, Y. Akachi¹, V. Alanis¹, JC. Sala¹, D. Hernandez¹, F. Varela¹

¹*Ingeniería en Ciencia de Datos y Matemáticas*

SUMMARY: El artículo examina el uso de técnicas de análisis topológico de datos (TDA) y redes neuronales convolucionales (CNN) para mejorar la detección de ondas gravitacionales, fenómenos predichos por la teoría de la relatividad general de Einstein y observados por primera vez en 2015 por el observatorio LIGO. Al integrar TDA y CNN, el estudio aborda cómo estos métodos avanzados permiten un análisis más eficiente y menos susceptible al ruido de los datos capturados por interferómetros, mejorando significativamente la capacidad de identificar ondas gravitacionales generadas por eventos cósmicos catastróficos, como la fusión de agujeros negros y estrellas de neutrones. Además, se destaca el desarrollo y la aplicación de datos sintéticos para simular ondas gravitacionales, facilitando el entrenamiento y validación de modelos predictivos. Este enfoque no solo mejora la precisión en la detección de ondas sino que también garantiza la protección de la privacidad y la seguridad de la información. Asimismo, el artículo detalla técnicas como el "Sliding Window Embedding" para capturar la dinámica temporal de los datos, lo que permite una visualización y análisis más efectivos de los fenómenos estudiados.

Key words. Datos sintéticos, Ondas gravitacionales, Análisis Topológico de Datos (TDA), Redes neuronales convolucionales (CNN).

1. INTRODUCCIÓN

Las ondas gravitacionales, una de las predicciones más fascinantes de la teoría de la relatividad general de Einstein. Estas ondas son ondulaciones en el tejido del espacio-tiempo causadas por eventos cósmicos extremos, como la fusión de agujeros negros y estrellas de neutrones. La detección de estas ondas por primera vez en 2015 por el observatorio LIGO revolucionó nuestra comprensión del universo. Las ondas gravitacionales nos permiten observar fenómenos muy energéticos o escondidos en el universo. Como viajan sin ser alteradas, los astrofísicos pueden usarlas para estudiar eventos que de otra manera serían invisibles, brindando una visión sin precedentes. Además, estas ondas extienden los límites de la física teórica, ofreciendo pruebas directas de las predicciones de la relatividad general en condiciones extremas de campos gravitacionales fuertes. El estudio de estas ondas también podría ayudar a resolver grandes misterios de la física, como la naturaleza de la materia oscura y la energía oscura, que constituyen aproximadamente el 95 por ciento del universo.

El presente artículo muestra cómo se detectan estas ondas usando dos técnicas principales: el análisis de datos topológicos (TDA) y las redes neuronales convolucionales (CNN). Estos métodos ayudan a lidiar con el ruido en los datos de los interferómetros, los dispositivos que detectan las ondas. El ruido, en este contexto, se refiere a las interferencias y señales no deseadas que pueden dificultar la identificación clara de las ondas gravitacionales.

Para comprender mejor cómo estos métodos funcionan, necesitamos introducir un concepto esencial: la topología. Imagina que tienes una hoja de papel que puedes doblar y estirar, pero sin romper ni pegar. Aunque la forma cambia, ciertas propiedades, como estar conectada o tener un único borde, permanecen igual. Esto es lo que estudia la topología: las propiedades de los espacios que no cambian bajo deformaciones suaves como estiramientos y torsiones. A diferencia de la geometría, que se enfoca en medidas y formas precisas, la topología se ocupa de características más generales y flexibles.

La topología no solo es una curiosidad matemática. Tiene aplicaciones en muchos campos: en matemáticas puras, ayuda a entender estructuras

complejas; en física teórica, se usa para estudiar fenómenos como las ondas y la teoría de cuerdas; en biología, para analizar la estructura del ADN y otras moléculas; en informática, para optimizar redes y algoritmos; y en economía y ciencias sociales, para modelar sistemas complejos. Además, la topología se aplica en el diseño de redes de comunicación, sistemas mecánicos, arte, arquitectura y medicina, especialmente en técnicas de imagen y análisis de tejidos. Con el avance tecnológico, su relevancia crece en áreas emergentes como la inteligencia artificial, ciencia de materiales y biotecnología, demostrando ser una herramienta valiosa para innovar y resolver problemas complejos.

En nuestro estudio de las ondas gravitacionales, la topología nos permite comprender e interpretar las formas de los datos, que en este caso son las señales generadas por las ondas gravitacionales. Al aplicar el análisis de datos topológicos (TDA) combinado con redes neuronales convolucionales (CNN), podemos identificar y clasificar señales de ondas gravitacionales de manera más general y resistente a las interferencias. TDA ayuda a identificar patrones importantes en los datos, incluso cuando hay muchas señales no deseadas, mientras que las CNN son buenas para encontrar y clasificar esos patrones de manera precisa. Al incorporar características topológicas extraídas mediante homología persistente, el modelo puede identificar y clasificar señales de ondas gravitacionales de manera más efectiva, permitiendo detecciones más frecuentes y fiables de estos fenómenos.

Así, la topología se convierte en una herramienta crucial para el análisis y la interpretación de los datos de ondas gravitacionales, permitiéndonos avanzar en nuestro entendimiento del universo y sus misterios.

2. CONCEPTOS

2.1. CNN (Redes Convolucionales)

Las redes convolucionales son un tipo de red neuronal utilizada principalmente en el análisis de imágenes. Funcionan como el cerebro humano, aprendiendo a identificar características importantes de las imágenes para tareas como el reconocimiento de objetos y la clasificación. Por ejemplo, imagina un sistema que puede aprender a identificar gatos en fotos después de ver suficientes ejemplos. (8)

2.2. Hiperparámetros

En el contexto del aprendizaje automático, los hiperparámetros son configuraciones que se establecen antes de entrenar un modelo, como la tasa de aprendizaje o el número de capas en una red neuronal. Son como los ajustes que se realizan antes de empezar una receta de cocina, determinando cómo se va a preparar todo. (11)

2.3. Ondas Gravitacionales

Las ondas gravitacionales son ondulaciones en el tejido del espacio-tiempo causadas por eventos cósmicos masivos, como la colisión de agujeros negros. Detectarlas nos permite “escuchar” el universo y descubrir fenómenos que no podemos ver con telescopios tradicionales. (13)

2.4. SNR (Signal-to-Noise Ratio)

La relación señal-ruido mide la calidad de una señal comparándola con el ruido de fondo. Es crucial en telecomunicaciones, ya que determina la claridad de las llamadas o la calidad de la transmisión de datos. Piensa en tratar de escuchar una conversación en una sala ruidosa; el SNR te dice qué tan bien puedes entender a la otra persona. (6)

2.5. Reducción de Dimensiones

Esta técnica simplifica datos complejos reduciendo el número de variables necesarias para describirlos, sin perder información importante. Es como tomar una foto de un objeto tridimensional: la imagen en 2D aún muestra lo esencial sin toda la complejidad original. (10)

2.6. Complejo Simplicial

Un complejo simplicial es una estructura matemática utilizada para estudiar formas y espacios de manera más manejable, descomponiéndolos en partes más simples llamadas “simplices”. Por ejemplo, imagina descomponer una figura compleja en triángulos para entender mejor su forma.

2.7. Vietoris-Rips

Este es un método para construir un complejo simplicial a partir de un conjunto de puntos, conectando puntos que están cerca unos de otros, es decir, por medio de la distancia. Ayuda a entender la estructura subyacente de datos dispersos, como identificar grupos o patrones en un conjunto de datos. (12)

2.8. Número de Betti

Los números de Betti son herramientas matemáticas que cuantifican la cantidad de agujeros en diferentes dimensiones de un espacio. Por ejemplo, una esfera tiene un número de Betti que indica que tiene un agujero en el centro. Nos ayudan a entender la topología de un espacio de forma cuantitativa. (7)

$$\left(\dim = \frac{\ker(\delta_p)}{\text{Im}(\delta_{p+1})} \right)$$

2.9. Epochs

En el aprendizaje automático, una epoch es una pasada completa a través del conjunto de datos de entrenamiento, es decir como una generación. Imagina practicar una pieza musical: cada vez que tocas la pieza de principio a fin, completas una epoch. Con suficientes epochs, el modelo aprende mejor el patrón en los datos. (3)

3. DATOS SINTÉTICOS

Para la realización del proyecto, se optó por la implementación de datos sintéticos, esto debido a que actualmente, la ciencia de datos enfrenta desafíos significativos debido a la escasez de datos de alta calidad que son esenciales para el desarrollo y validación de modelos avanzados de inteligencia artificial. Para estos casos, los datos sintéticos proporcionan un medio para generar información que imita las características estadísticas de los datos reales sin comprometer la privacidad o seguridad de los datos personales. Este enfoque no solo asegura la privacidad y la seguridad de la información, sino que también permite la generación de datos bajo condiciones controladas y específicas que serían difíciles o imposibles de replicar en la realidad.

Su fabricación se da mediante algoritmos que permiten mantener la estructura y propiedades de los datos originales, tales como métodos de remuestreo, modelado probabilístico, generativo, y técnicas de perturbación y enmascaramiento, lo que los hace particularmente útiles en entornos donde los datos reales son limitados o donde la privacidad es una preocupación predominante. (5)

Es por ello que la implementación de datos sintéticos ofrece varias ventajas significativas:

- **Accesibilidad:** Superan la falta de datos reales, facilitando el acceso a información necesaria para la investigación.
- **Privacidad y Seguridad:** Evitan la exposición de datos confidenciales, protegiendo la privacidad durante pruebas y desarrollo.
- **Flexibilidad y Escalabilidad:** Permiten experimentar con nuevas técnicas sin los costos asociados con datos reales.
- **Calidad y Fidelidad:** Se ajustan para reflejar fielmente las características de los datos reales, validados mediante comparaciones rigurosas.

Sin embargo, los datos sintéticos también presentan algunas limitaciones:

- **Complejidad en la Creación:** Requieren métodos avanzados y recursos considerables para su generación precisa.
- **Riesgo de Sesgo:** Pueden incorporar sesgos si los algoritmos no están correctamente diseñados, afectando la validez de los resultados.

3.1. Relación con la Detección de Ondas Gravitacionales

En específico, para la detección de ondas gravitacionales, los datos sintéticos se utilizan para entrenar y probar algoritmos de detección donde se generan señales que simulan las ondas gravitacionales producidas por fusiones de agujeros negros por ejemplo, mezcladas con ruido aleatorio. (1) Esto permite lo siguiente:

- **Entrenamiento eficaz:** Proporciona un gran conjunto de datos balanceado para entrenar el modelo.
- **Mejor manejo del ruido:** Permite probar el algoritmo en condiciones controladas con diferentes niveles de ruido.

3.2. Otras aplicaciones de los datos sintéticos

- **Medicina:** Entrenan algoritmos de diagnóstico sin comprometer la privacidad de los pacientes.
- **Seguridad y privacidad:** Simulan ataques para evaluar sistemas de defensa.
- **Inteligencia Artificial:** Entrenan modelos cuando los datos reales son escasos.
- **Pruebas de software:** Simulan condiciones controladas para probar aplicaciones.

Entonces resumiendo, los datos sintéticos son esenciales para entrenar y evaluar modelos en la detección de ondas gravitacionales y en muchas otras áreas, mejorando la eficacia y protegiendo la privacidad. (9)

A continuación, se describe el proceso para la generación de los datos sintéticos:

3.3. Generación de Señales de Referencia

Se generaron 1500 señales de referencia que simulan ondas gravitacionales producidas por la fusión de agujeros negros binarios, las cuales se hicieron mediante la creación de nubes de puntos. Las nubes de puntos se crearon para tres formas geométricas: círculos, esferas y toros, con ruido aleatorio añadido para cada punto. Cada forma se etiquetó con un valor único: 0 para círculos, 1 para esferas y 2 para toros.

Las señales de ondas gravitacionales se generaron a partir de datos preexistentes, ajustando la frecuencia de muestreo mediante un factor de reducción. Los coeficientes de escala se seleccionaron aleatoriamente dentro del rango de 0.075 a 0.65. Cada señal tenía una duración de 2 segundos, con una probabilidad del 50% de que contuviera una onda gravitacional.

Cada señal tiene una duración de 2 segundos y se muestrea a una frecuencia de 2048 Hz. Para cada

relación de masa, se creó una señal que varía linealmente en frecuencia desde 10 Hz hasta 100 Hz, lo que imita la evolución de la frecuencia de una onda gravitacional:

$$\text{signal}(t) = \text{chirp}(t, f_0 = 10 \text{ Hz}, f_1 = 100 \text{ Hz}, t_1 = 2 \text{ s})$$

3.4. Inserción de Ruido y Señales

Para cada señal de referencia, se añadió ruido gaussiano y se decidió aleatoriamente un punto de inicio dentro de una ventana de tiempo de 2.976 segundos. El ruido gaussiano se generó con una desviación estándar de 1. Se escaló con un coeficiente de escala adimensional R seleccionado aleatoriamente entre 0.075 y 0.65. La ecuación para los datos sintéticos es:

$$s = g + E \frac{1}{R} \xi \quad (1)$$

donde g es la señal de referencia, ξ es el ruido gaussiano, y E es una constante pequeña ($1e-19$).

El proceso para añadir ruido e insertar la señal es el siguiente:

$$\begin{aligned} \text{noise} &= \mathcal{N}(0, 1, \text{total.length}) \\ \text{scaled_noise} &= E \times \left(\frac{1}{R} \right) \times \mathcal{N}(0, 1, N) \end{aligned}$$

$$\begin{aligned} \text{embedded_signal} &= \text{scaled_noise} + \text{padding_before} \\ &\quad + g + \text{padding_after} \end{aligned}$$

Si la señal está presente (probabilidad de 0.5), se selecciona un índice de inicio aleatorio y se inserta la señal en el ruido, añadiendo padding aleatorio antes y después de la señal. Este proceso garantiza que las señales sintéticas sean lo suficientemente variadas y realistas para entrenar y validar modelos de detección y análisis de ondas gravitacionales.

3.5. Generación del Conjunto de Datos de Entrenamiento

Cada señal de referencia se procesó para generar datos de entrenamiento. Esto incluyó la adición de ruido y la inserción de la señal en un punto de inicio aleatorio. El conjunto de datos resultante contiene las señales embebidas en ruido junto con el tiempo de inicio de cada señal:

$$\text{training_data} = \{(\text{embedded_signal}_i, \text{start_time}_i)\}_{i=1}^{1500}$$

Este proceso garantiza que los datos sintéticos sean lo suficientemente variados y realistas para entrenar y validar modelos de detección y análisis de ondas gravitacionales.

3.6. Visualización de una Señal de Ejemplo

Es relevante visualizar una señal de ejemplo para entender cómo se comporta la señal de onda gravitacional embebida en ruido. Esta visualización permite verificar que la señal se ha insertado correctamente en el ruido y evaluar la relación señal/ruido en el contexto de la simulación.

Para cargar y graficar una señal de ejemplo, se siguieron los siguientes pasos:

- Cargar los datos de las señales desde los arreglos generados por el proceso de simulación.
- Identificar el índice correspondiente a la primera serie temporal de ruido puro y a la primera serie temporal de ruido con onda gravitacional.
- Generar un vector de tiempo para las señales basado en la frecuencia de muestreo.
- Graficar las señales, indicando claramente las componentes de ruido y la señal de onda gravitacional.

En primera gráfica resultante 1, se puede observar la señal completa con ruido puro. La línea azul representa el ruido generado sin ninguna señal de onda gravitacional insertada. Esta visualización es importante para entender el nivel base de ruido presente en las simulaciones.




Fig. 1: Señal de ruido puro.

Por su parte, la Figura 2 muestra una señal de ruido con una onda gravitacional embebida. La línea roja representa el ruido de fondo, mientras que la línea verde muestra la señal de onda gravitacional. Esta visualización es crucial para verificar la correcta inserción de la señal y para analizar la interacción entre la señal y el ruido. Al observar la relación entre el ruido (línea roja) y la señal (línea verde), se puede evaluar la eficacia de los métodos de detección y análisis de ondas gravitacionales en condiciones de ruido realista.




Fig. 2: Visualización de una señal de ruido con onda gravitacional. La línea roja muestra el ruido con la señal embebida, mientras que la línea verde destaca la señal de onda gravitacional real inserta en el ruido.

4. SLIDING WINDOW EMBEDDING Y HOMOLOGÍA PERSISTENTE

Para la detección de ondas gravitacionales, la combinación de técnicas como Sliding Window Embedding y la Homología persistente permiten identificar y extraer características clave de las señales de ondas gravitacionales, diferenciándolas eficazmente del ruido predominante de los datos recogidos por los detectores, en nuestro caso de los datos sintéticos (2).

4.1. Sliding Window Embedding

El Sliding Window Embedding es una técnica que implica tomar pequeños segmentos de una serie temporal y transformarlos en representaciones de alta dimensión. Esto es especialmente útil en el contexto de la detección de ondas gravitacionales, donde las señales son débiles y están frecuentemente ocultas por el ruido (3).

Aplicar esta técnica, facilita la identificación de patrones periódicos característicos de las ondas gravitacionales dentro de los datos ruidosos. Para entenderlo mejor, este proceso es análogo a escuchar fragmentos continuos de una melodía que permiten reconocer una canción, incluso en presencia de interrupciones.

4.2. Homología Persistente

La Homología Persistente es una herramienta del análisis topológico de los datos que identifica y mide características geométricas importantes en diferentes escalas (4).

Aplicar esta técnica a los datos de ondas gravitacionales, se pueden destacar patrones significativos que persisten a través de múltiples escalas, filtrando el ruido y capturando las verdaderas señales de interés.

Para entenderlo mejor, esta metodología es comparable a observar una serie de fotos donde

únicamente los patrones consistentes a lo largo del tiempo de mantienen visibles, mientras que los detalles transitorios se desvanecen.

4.3. Ventajas de su uso

Utilizar estas dos técnicas nos proporciona varios beneficios esenciales para la detección de las ondas gravitacionales:

- **Mejora de la Detección en Ruido:** Al transformar los datos en una representación topológica, nos permite distinguir las señales auténticas de ondas gravitacionales del ruido, aumentando significativamente la precisión de la detección. Esto es fundamental, ya que las señales de ondas gravitacionales son extremadamente débiles y fácilmente escondidas por el ruido.
- **Reducción del Volumen de Datos de Entrenamiento:** El uso de esas técnicas permiten entrenar modelos de detección con conjuntos de datos más pequeños, lo cual es ventajoso dado el alto costo y la complejidad de recopilar y procesar grandes volúmenes de datos.
- **Mayor Generalidad y Robustez:** Las ondas gravitacionales pueden tener diversas formas y características según los eventos cósmicos que las generan, como la fusión de agujeros negros. Estas técnicas hacen que el modelo tenga mayor flexibilidad para detectar una variedad más amplia de señales.

4.4. Aplicación de las técnicas

Ahora, para aplicar las técnicas de Homología Persistente y Sliding Window Embedding a la señal generada con los datos sintéticos el cual contiene la onda gravitacional se llevó a cabo la siguiente metodología.

Primeramente, el objetivo de este proceso fue transformar una señal de onda gravitacional en una nube de puntos embebida en un espacio de alta dimensión. Esto con el fin de identificar y visualizar los patrones intrínsecos de la señal, diferenciándolos del ruido de fondo.

Sliding Window nos permite calcular la estructura temporal de la serie de datos al mapear ventanas deslizantes de tamaño m a nuestra serie temporal. Para cada ventana, extraemos un conjunto de características que representan la dinámica local de la serie temporal en ese intervalo, lo cual puede incluir valores de la serie temporal en el intervalo, derivadas u otras medidas relevantes.

En nuestra implementación, la incrustación de Sliding Window Embedding se realiza utilizando parámetros que controlan el tamaño y la configuración de la ventana deslizante utilizada para mapear subconjuntos secuenciales de puntos de datos en nuestra serie temporal:

- **Dimensión de Embedding Máxima:** Dimensión del espacio en la cual la serie temporal será embebida. Aumentar la dimensión nos ayuda a capturar más información de la señal, ya que nos permite analizarla con más profundidad y detalles (como de una película 2D a 3D). En este caso se utilizó una dimensión máxima de 30, por lo que cada punto de la serie temporal será representado en un espacio tridimensional.
- **Retrdo de Tiempo Máximo de Embedding:** Intervalo de tiempo entre los puntos sucesivos en cada segmento que se está analizando. Esto ayuda a capturar la periodicidad o repetición en la señal. En este caso se estableció un tiempo de retardo de 30, por lo que se toma cada punto considerando los 30 puntos anteriores en la serie.
- **Stride:** Número de puntos que se avanza antes de tomar el siguiente segmento. En este caso tenemos un stride de 5, lo que significa que la ventana deslizante se mueve 5 puntos a la vez, es decir que cada nuevo segmento de datos que se analiza comienza 5 puntos después del segmento anterior.

Una vez establecidos los parámetros se crea el Embedding, que en este caso se utilizó el **Single Takens Embedding**. Esta es una técnica que aplica el concepto de ventana deslizante a la serie temporal, transformándola en una nube de puntos en un espacio de dimensión superior. Este proceso permite capturar la estructura geométrica de la señal original, destacando los patrones periódicos.

Dicho Embedding fue utilizada para 3 señales: la señal de únicamente una onda gravitacional, la señal de ruido puro sin insertar una onda gravitacional y la señal de la onda gravitacional con ruido. Una vez realizado la transformación, para poder obtener la visualización de la nube de puntos debemos bajar la dimensionalidad ya que estamos tratando con una dimensionalidad máxima de 30. En este caso vamos a bajarlo a 3, para lograr esto hacemos uso de Componentes Principales.

Análisis de Componentes Principales (PCA) es una técnica que toma un montón de información complicada y la resume en unas pocas características principales, haciendo más fácil entender las diferencias importantes en los datos. Para poder entenderlo mejor, imaginemos que tenemos una caja llena de diferentes tipos de frutas y queremos organizar estas frutas de manera que sea más fácil entender las principales diferencias entre ellas. Aquí es donde se usa PCA que en lugar de ver cada fruta en detalle, este encuentre las características más importantes que hacen que las frutas sean diferentes entre sí. Es como si alguien tomara todas esas características y las resumiera en pocas dimensiones más fáciles de entender como el tamaño de las frutas y la forma de la fruta.

Una vez hecha el PCA a 3 dimensiones, se generó

las nubes de puntos que representa la serie temporal en el espacio embebido.

Finalmente, se pudo visualizar la nube de puntos resultantes de la transformación. Esta es de gran utilidad para identificar visualmente los patrones topológicos en la señal transformada.

Esta combinación de técnicas nos proporciona una base sólida para el análisis y la interpretación de conjuntos de datos complejos, permitiéndonos explorar y comprender la estructura inherente de los fenómenos que estamos estudiando de manera más efectiva.

A continuación, en la Figura 3, podemos observar la nube de puntos sacada de la transformación del Sliding Window Embedded de la señal de la onda gravitacional embebida con los parámetros que se mencionaron anteriormente.




Fig. 3: Sliding Window de la ONDA GRAVITACIONAL.

Observando la nube de puntos generada en la Figura 3, vemos que la señal generada por el nacimiento de un agujero negro emerge como una espiral en el espacio de tiempo embebido en retardo. Para lograr detectar una onda gravitacional, se debe de encontrar este tipo de patrones (espirales) dentro de los ruidos.

Ahora a continuación en la Figura 4 vemos el Sliding Window Embedded del ruido puro, es decir, sin una onda gravitacional.




Fig. 4: Sliding Window del RUIDO PURO.

En esta gráfica vemos una nube de puntos sin ningún patrón o ciclo. Esto pasa porque evidentemente es ruido puro, por lo que forma una bola en el espacio creado.

Ahora analizaremos el Sliding Window Embedded de las señales con ruido con diferente valor de R para observar patrones.




Fig. 5: SW de onda gravitacional con ruido y $R=0.075$




Fig. 6: SW de onda gravitacional con ruido y $R=0.3625$




Fig. 7: SW de onda gravitacional con ruido y $R=0.65$

Comparando las Figuras 5, 6 y 7, vemos que entre mayor es el valor de R , se verán puntos más dispersos, los que nos puede ayudar a encontrar patrones y ciclos que puedan detectar a la onda gravitacional. Es por eso que entre mayor sea el valor de R más fácil será identificar si en una señal con ruido existe la presencia de una onda gravitacional.

5. Redes Convolucionales (CNN)

La implementación de las redes convolucionales en este estudio fue debido a sus notables ventajas en el análisis de datos complejos y su capacidad para manejar grandes volúmenes de información de manera eficiente. Además, las CNN son particularmente útiles para el reconocimiento de patrones en datos espaciales y temporales, por lo tanto, las CNN proporcionan una metodología robusta para la detección de ondas gravitacionales.

5.1. Ventajas de su uso

Algunas ventajas de la implementación de las CNN son:

- **Detección de Patrones Complejos:** Las CNN son capaces de aprender y detectar patrones complejos en los datos, lo cual es esencial para identificar las sutiles señales de ondas gravitacionales entre el ruido de fondo.
- **Invariancia Espacial:** Gracias a su arquitectura, las CNN pueden reconocer patrones en cualquier parte del campo visual, lo que es crucial para detectar ondas gravitacionales que pueden ocurrir en cualquier momento y lugar dentro de los datos.
- **Reducción de la Dimensionalidad:** Las capas convolucionales reducen la dimensionalidad de los datos, lo que disminuye el tiempo de procesamiento y la carga computacional sin perder información relevante.

- **Eficiencia en el Procesamiento de Datos:** Las CNN están diseñadas para procesar grandes volúmenes de datos de manera eficiente, lo cual es fundamental cuando se trabaja con datos de alta resolución como los capturados por interferómetros.
- **Capacidad de Generalización:** Al ser entrenadas con un gran conjunto de datos, las CNN pueden generalizar bien a nuevos datos no vistos, lo que mejora la precisión y la fiabilidad en la detección de ondas gravitacionales.

5.2. Integración TDA

La implementación de CNN en este estudio se realiza en conjunto con técnicas de TDA, lo que proporciona las siguientes ventajas adicionales:

- **Captura de Estructuras Topológicas:** El TDA permite identificar y cuantificar las características topológicas de las señales, como agujeros y ciclos persistentes, que son útiles para distinguir entre ondas gravitacionales y ruido.
- **Mejora de la Robustez del Modelo:** Al integrar características topológicas en las CNN, se mejora la capacidad del modelo para resistir el ruido y detectar patrones de manera más efectiva.
- **Análisis Multiescala:** El TDA permite analizar las señales en múltiples escalas, proporcionando una visión más completa y detallada de las estructuras presentes en los datos.

Al combinar CNN con TDA, se logra un enfoque integral que maximiza la capacidad de detectar ondas gravitacionales en datos ruidosos. Las CNN se encargan de la extracción y clasificación de características, mientras que el TDA aporta información topológica crucial que mejora la precisión y la fiabilidad del modelo.

5.3. Preparación y Procesamiento de Datos

Antes de implementar la red neuronal, se realiza una serie de pasos de preparación y procesamiento de datos para asegurar que las señales de ondas gravitacionales estén adecuadamente representadas y que las características relevantes sean extraídas de manera efectiva. El proceso realizado fue el siguiente:

1. **Incrustación de Takens:** Se utiliza la incrustación de Takens para transformar las señales de tiempo en espacios de alta dimensión, permitiendo capturar la dinámica temporal de las señales.

- **Parámetros utilizados:** dimensión de incrustación = 30, retardo de tiempo = 30, y stride = 5.
- La función `SingleTakensEmbedding` se encarga de realizar esta transformación.

2. **Reducción de Dimensionalidad:** Se aplica PCA (Análisis de Componentes Principales) para reducir la dimensionalidad de las señales incrustadas, facilitando el cálculo de la homología persistente.

- Número de componentes principales utilizados: 3.

3. **Cálculo de Homología Persistente:** Se utiliza `VietorisRipsPersistence` para calcular la homología persistente de las señales transformadas. Este proceso permite identificar características topológicas importantes como agujeros y ciclos persistentes en los datos.

- Dimensiones de homología consideradas: 0 y 1.

4. **Preparación de los Datos para la Red Neuronal:**

- Se extraen los tiempos de vida de las características de homología persistente (H_0 y H_1).
- Se asegura que todos los vectores de tiempos de vida tengan la misma longitud mediante padding.
- Se crea un DataFrame con los tiempos de vida, proporcionando una representación estructurada de las características topológicas.

5.4. Ejemplo

Para lograr entender de mejor manera este proceso a continuación se presenta un ejemplo.

El primer paso que se realiza es hacer el Sliding Window Embedding y la Homología Persistente de una señal como se explicó en la Sección 4. Una vez hecho esto, se generó un Diagrama de Persistencia para entender de mejor manera el proceso de esa señal, véase la Figura 8.




Fig. 8: Diagrama de persistencia de una señal

Un Diagrama de Persistencia es una herramienta visual que se usa para mostrar cómo varían las características de algo a lo largo del tiempo o en diferentes condiciones.

Para entenderlo mejor, imaginemos que estamos observando cómo cambia la altura de una planta mientras crece. Un diagrama de persistencia nos ayudaría a ver, de manera clara y ordenada, en qué momentos la planta crece más rápido y en qué momentos crece más lento.

En términos más generales, este tipo de diagrama nos muestra qué tanto persisten (o duran) ciertos patrones o comportamientos en un conjunto de datos. Por ejemplo, si estamos viendo la temperatura en una ciudad a lo largo del año, un diagrama de persistencia te ayudaría a identificar cuánto tiempo duran las olas de calor o las olas de frío.

Es como una manera fácil de ver las “huellas” que dejan los datos a lo largo del tiempo, ayudándote a entender mejor el comportamiento de lo que estamos estudiando.

Por lo tanto, vamos a usar estas características para entrenar nuestra red neuronal. Lo que vamos a extraer de este diagrama es el tiempo de vida que tiene cada punto. En este caso únicamente analizamos H_0 y H_1 porque H_0 nos podría indicar los segmentos de la señal donde hay patrones coherentes, es decir, donde la señal se agrupa en formas reconocibles por encima del ruido. Mientras que H_1 nos puede mostrar los ciclos o patrones repetitivos en la señal, indicando oscilaciones o estructuras recurrentes en la señal.

Por ende, generamos un vector de datos para cada señal en donde incluye el tiempo de vida de cada punto de H_0 y H_1 en ese orden y de mayor a menor.

$$\Pi = (\Pi^0, \Pi^1)$$

En donde Π^i es el tiempo de vida de cada punto de H_i

Finalmente, juntamos la señal con ruido de cada una de las señales después de estos valores de Π y este vector de datos será la entrada para nuestra red neuronal convolucional.

$$x = (\Pi, \text{señal})$$

5.5. Arquitectura de la CNN

Para construir la red CNN, en primer lugar, se prepararon los datos, para eso, lo que se hizo fue normalizarlos para que todos los valores estuvieran dentro del mismo rango, y luego se dividieron en dos grupos, uno para entrenar la red y otro para probar qué tan bien aprendió. Hay que tener en cuenta que los datos son señales que se tuvieron que convertir en una forma que la red los pudiera procesar, para eso, hay que imaginar que lo que se hizo fue tomar una larga fila de números y organizarla en una cuadrícula.

La red neuronal comienza con una capa de entrada que simplemente recibe los datos. Posterior-

mente, se aplican las capas convolucionales, donde la primera capa funciona como una lupa que se mueve sobre la cuadrícula de datos buscando características simples como líneas o bordes. La segunda capa de convolución usa una “lupa” más avanzada que busca combinaciones de características simples encontradas por la primera lupa, como formas y texturas. Y la tercera capa de convolución utiliza una lupa final que busca combinaciones aún más complejas, como patrones específicos que podrían indicar la presencia de una onda gravitacional.

Después de cada capa de convolución, tenemos una capa de normalización que ajusta los valores para que el aprendizaje sea más estable y rápido, similar a nivelar el terreno antes de seguir construyendo. Y también incluimos capas de agrupación (pooling) que reducen el tamaño de la cuadrícula, tomando solo los valores más importantes, lo que sería como hacer una foto más pequeña pero manteniendo los detalles más esenciales, esto ayuda a reducir la cantidad de cálculos necesarios y evita el sobreajuste. Una vez que se pasa por varias capas de convolución y agrupación, se transforma la cuadrícula en una fila de números de nuevo, y de esta forma prepararla para la toma de decisiones final en la capa de aplanamiento (flattening).

En la siguiente tabla se muestra de forma secuencial la arquitectura de la red CNN:

Num	Tipo	Parámetro
1	Input	
2	Convolution	32, strides = 1, kernel.size = 3
3	BatchNorm	32
4	ReLU	
5	Max Pooling	strides = 2, pool.size = 2
6	Convolution	64, strides = 1, kernel.size = 3
7	BatchNorm	64
8	ReLU	
9	Max Pooling	strides = 2, pool.size = 2
10	Convolution	128, strides = 1, kernel.size = 3
11	BatchNorm	128
12	ReLU	
13	Max Pooling	strides = 2, pool.size = 2
14	Flatten	
15	Dense	512, Linear
16	BatchNorm	512
17	ReLU	
18	Dropout	0.5

Table 1: Arquitectura de la CNN (Parte 1)

Num	Tipo	Parámetro
19	Dense	256, Linear
20	BatchNorm	256
21	ReLU	
22	Dropout	0.5
23	Dense	128, Linear
24	BatchNorm	128
25	ReLU	
26	Dropout	0.5
27	Dense	2, Linear

Table 2: Arquitectura de la CNN (Parte 2)

Entonces, hasta este punto los datos pasan por varias capas completamente conectadas, que resumiéndolas, la primera capa toma todos los números y aprende combinaciones complejas de características, después la segunda refina aún más las decisiones, haciendo ajustes basados en lo que se ha aprendido hasta ahora, y la tercera capa hace los ajustes finales, preparando la red para decidir si una señal contiene una onda gravitacional o no. Entre estas capas, también se utilizan capas de normalización para mantener los valores estables y capas de abandono (dropout) para evitar que la red dependa demasiado de cualquier característica en particular, mejorando así su capacidad de generalización. La capa de salida es la última capa de la red y decide entre dos opciones, que son, onda gravitacional presente o no presente, dando así la respuesta final.

Durante el entrenamiento de la red, pasamos los datos a través de ella, calculamos cuánto se equivoca y ajustamos la red para que aprenda a reconocer las ondas gravitacionales. Repetimos este proceso muchas veces (épocas) hasta que la red aprenda bien, y finalmente, se probó la red con el grupo de datos de prueba para ver qué tan bien pudo identificar las ondas gravitacionales y se visualizaron los resultados para entender mejor el rendimiento de la red.

5.6. Resultados


Después de correr 30 generaciones obtuvimos los siguientes resultados:

En este caso, la precisión es del **74 %**, lo que indica que el modelo necesita mejoras, especialmente dado que la pérdida es 0.43 durante el entrenamiento. Sin embargo, considerando la dificultad que tiene encontrar señales que contengan ondas gravitacionales se puede considerar que este es un buen resultado. En la Figura 9 podemos observar el resultado de las últimas épocas de entrenamiento.

```
Epoch 17/50, Loss: 0.6097, Test Accuracy: 0.5500
Epoch 18/50, Loss: 0.5874, Test Accuracy: 0.7033
Epoch 19/50, Loss: 0.5468, Test Accuracy: 0.5100
Epoch 20/50, Loss: 0.5124, Test Accuracy: 0.7400
Epoch 21/50, Loss: 0.4978, Test Accuracy: 0.6067
Epoch 22/50, Loss: 0.4796, Test Accuracy: 0.5967
Epoch 23/50, Loss: 0.4839, Test Accuracy: 0.5500
Epoch 24/50, Loss: 0.4571, Test Accuracy: 0.6533
Epoch 25/50, Loss: 0.4497, Test Accuracy: 0.6367
Epoch 26/50, Loss: 0.4492, Test Accuracy: 0.6233
Epoch 27/50, Loss: 0.4436, Test Accuracy: 0.6400
Epoch 28/50, Loss: 0.4239, Test Accuracy: 0.6167
Epoch 29/50, Loss: 0.4351, Test Accuracy: 0.6267
Epoch 30/50, Loss: 0.4367, Test Accuracy: 0.6567
Early stopping!
Best Test Accuracy: 0.7400
```

Fig. 9: Últimas épocas

Para evaluar más los resultados de la red neuronal convolucional se generó la curva de ROC. Esta es una herramienta que se usa para evaluar la precisión de un modelo que hace predicciones, especialmente en clasificación. El eje Y muestra cuántas veces el modelo acierta cuando dice que algo es verdadero. Mientras que el eje X muestra cuántas veces el modelo se equivoca cuando dice que algo es verdadero pero no lo es. Un buen modelo tendrá una gráfica ROC que se acerque más a la esquina superior izquierda, lo que significa que acierta mucho y se equivoca poco. En la Figura 10 vemos la gráfica ROC de nuestro modelo.


Fig. 10: Gráfica de ROC

Como podemos observar no tenemos un resultado muy bueno ya que la línea no se acerca mucho a la esquina superior izquierda, no obstante este tiene la tendencia de comportarse como queremos si aumentamos las épocas. Esto lo podemos comprobar con la Figura 11.




Fig. 11: Gráfica Accuracy vs Época

Observando la gráfica de Accuracy vs Época podemos observar que efectivamente mientras más épocas pasan, va mejorando el modelo ya que podemos ver una tendencia con una pendiente positiva. En este caso, debido a que cada época utilizaba muchos recursos computacionales y por lo tanto mucho tiempo en cada ciclo, se decidió cortar en las 30 épocas, no obstante, se espera que entre más ciclos se ejecuten mejor será la precisión y menor la pérdida del modelo. Tomando en cuenta que no debemos sobreentrenar el modelo.

6. Mapeado Topológico

En la topología, el mapeado topológico, o mapa topológico, es una función entre dos espacios topológicos que mantiene la estructura de apertura de los conjuntos. Para entenderlo mejor, veamos algunos conceptos clave:

- **Espacio topológico:** Conjunto de puntos, junto con una colección de subconjuntos llamados "abiertos" que cumplen ciertas propiedades. Estos subconjuntos abiertos nos ayudan a entender cómo se distribuyen y relacionan los puntos dentro del conjunto.
- **Función continua:** Una función es continua cuando los puntos cercanos a un espacio de entrada se mapean en puntos cercanos al espacio de salida.

Imaginemos que tenemos dos de estos espacios topológicos junto con una colección de subconjuntos llamados "abiertos" que cumplen ciertas propiedades. Estos subconjuntos abiertos nos ayudan a entender cómo se distribuyen y relacionan los puntos dentro del conjunto.

Para visualizarlo, pensemos en un espacio topológico como una hoja de papel. Un conjunto abierto es como dibujar un círculo en la hoja. Si se dobla o estira la hoja (haciendo una transformación continua), cualquier círculo que se dibuje en la hoja seguirá pareciendo un círculo, aunque quizás estirado o deformado, pero sin romperse.

- **Imagen inversa:** La imagen inversa de un conjunto V en Y es el conjunto de todos los puntos en X que, al ser mapeados por f terminan en V , como rastrear hacia atrás desde Y hasta X .
- **Homeomorfismo:** Es una función que no solo es continua, sino también biyectiva (cada punto en X se mapea a un punto único en Y y viceversa) y cuya función inversa también es continua. Básicamente, un homeomorfismo es una función que te permite "transformar" un espacio topológico en otro sin romper su estructura topológica, y es posible deshacer esa transformación sin perder dicha estructura.

Imaginemos una figura de plastilina (representando un espacio topológico) la cual se moldea sin romperla ni hacer agujeros (función continua), luego, puede volver a su forma original sin problemas (la inversa también es continua). Esto significa que los dos espacios son esencialmente "iguales" en términos de su estructura topológica, y por eso decimos que son homeomorfos.

6.1. Elección del Mapper

La elección del Mapper se debe a que es de gran utilidad en la detección de las ondas gravitacionales. En este caso, vamos a utilizar el Mapper para la detección de las ondas gravitacionales. Para este proyecto se utiliza para la clasificación de señales ya que las señales capturadas están mezcladas con mucho ruido. El Mapper ayuda a separar y clasificar estas señales, identificando patrones que nos indican la presencia de ondas gravitacionales.

Asimismo, el Mapper ayudaría en la reducción de complejidad, ya que como se mencionó anteriormente las señales de ondas gravitacionales pueden ser muy complejas y difíciles de analizar directamente. El uso del Mapper reduce esta complejidad, permitiendo visualizar y entender mejor las estructuras subyacentes.

Además, algunas veces, las ondas gravitacionales pueden tener patrones que no son evidentes debido al ruido. Mapper ayuda a descubrir estos patrones ocultos al agrupar señales similares y resaltar las diferencias importantes.

6.2. Importancia de su uso

En el contexto de la detección de ondas gravitacionales, el uso de mapper puede ser crucial debido a varios motivos:

- **Mejora la precisión:** El Mapper ayuda a diferenciar entre señales reales y ruido, mejorando así la precisión en la detección de ondas gravitacionales.
- **Facilita el análisis:** El uso del Mapper nos permite visualizar y analizar grandes volúmenes de datos de manera más manejable y comprensible.

- **Acelera el descubrimiento:** Como el Mapper identifica patrones y estructuras en los datos, este facilita el descubrimiento de nuevas ondas gravitacionales y por lo tanto mejoraría nuestra comprensión del universo.

6.3. Construcción del Mapeado Topológico

Para la construcción del mapeo topológico, se utilizó la biblioteca KeplerMapper, que permite visualizar y analizar la estructura de datos de alta dimensión. En este caso, se trabajó con las señales de ondas gravitacionales ya generados en la sección 3.3 y los coeficientes de escala adimensionales. A continuación se describe el proceso:

- Se importaron las bibliotecas necesarias: KeplerMapper y Scikit-learn, además de las funciones para clustering y manipulación de matrices de NumPy.
- Los datos de los coeficientes de escala (*Rcoeflist*) y las señales de ondas gravitacionales (*gw_signals*) se convirtieron en arreglos de NumPy para su manipulación eficiente.
- Se creó una instancia del objeto KeplerMapper con un nivel de verbosidad configurado en 1 para obtener información sobre el proceso.
- Se generó el grafo de mapeo topológico utilizando el método `map` de KeplerMapper, aplicando el algoritmo de clustering DBSCAN con métrica euclidiana. Se configuró la cubierta (*cover*) del mapeo con 6 cubos y un 5% de solapamiento.
- Se visualizó el grafo mediante el método `visualize` de KeplerMapper, generando un archivo HTML titulado "Ondas Gravitacionales". La visualización incluyó escalas de color personalizadas y tooltips con los coeficientes de escala. A continuación, se muestran los resultados obtenidos:



Fig. 12: Mapper ondas gravitacionales

Al desplegar el detalle de los clusters se pudo observar que cada pieza correspondían a la misma clasificación del coeficiente R.

7. Estadístico de prueba

Para comenzar a preparar las señales para poder obtener un estadístico de prueba, se creó una función que mide la distancia desde los puntos en el diagrama de persistencia hacia una línea recta definida por la diagonal en un espacio bidimensional.

Se tomó la decisión de usar diferentes tipos de distancia para observar cuál arrojaba mejores resultados al momento de evaluar el p-valor.

En primer lugar, la función llamada distancia, calcula esta distancia utilizando la distancia euclidiana entre cada punto del diagrama de persistencia y la línea diagonal. A continuación, se muestra la fórmula:

$$\text{distancia}(P) = \min_{Q \in \text{línea diagonal}} \|P - Q\| \quad (2)$$

En el caso de la distancia cuello de botella, calcula la distancia vertical más larga entre los puntos de un diagrama.

La fórmula correspondiente es:

$$\max_{\text{point} \in \text{diagram}} |\text{point}[1] - \text{point}[0]|$$




Fig. 13: Distancia hacia H_1

En la figura 13, se puede observar que para ambos tipos de distancia, se tomó el valor de cada punto en H_1 y se midió la distancia hacia la recta para ser medido en sus respectivas funciones de distancia.

A continuación, se generaron los diagramas de persistencia a todas las señales, y se calculó la homología persistente.

La función **calcular diagrama persistencia** trabaja en el cálculo de diagramas de persistencia a partir de señales de entrada. Utiliza la técnica de ventanas deslizantes para reducir la dimensionalidad de la señal y luego aplica un algoritmo de persistencia para obtener el diagrama. Esta función es crucial para entender la topología y estructura de los datos.

El cálculo del estadístico de prueba se basa en la evaluación de las distancias entre los puntos dentro de cada grupo formado por los diagramas de persistencia. En este proceso se recorre cada diagrama y suma las distancias entre los puntos relevantes. Sin embargo, solo suma las distancias si el diagrama tiene al menos un punto válido.

Debido a esto, la *función estadístico global* es la pieza central del análisis. Toma dos grupos de señales como entrada y calcula un estadístico global que compara las características topológicas de ambos grupos. Utiliza los diagramas de persistencia calculados previamente y pondera las distancias según coeficientes específicos para cada grupo. Este estadístico proporciona información valiosa sobre las diferencias estructurales entre los grupos de señales analizados.

El proceso realizado para el cálculo del estadístico fue el siguiente:

1. **Cálculo de la Distancia entre Pares de Señales:** Primero, se calcularon las distancias cuadradas entre todas las posibles parejas de señales dentro de cada grupo. Esto se expresa matemáticamente como:

$$\sigma_x^2 = \frac{1}{2n(n-1)} \sum_{i=1}^n \sum_{j=1}^n d_2(X_i, X_j)^2$$

Aquí, n es el número total de señales en un grupo y $d_2(X_i, X_j)$ representa la distancia cuadrada entre la señal X_i y la señal X_j .

2. **Extensión a Múltiples Grupos:** Dado que tenemos tres grupos, la fórmula se extiende sumando los términos de cada grupo:

$$\sigma_{\chi_{12}}^2(L) = \sum_{m=1}^3 \frac{1}{2n_m(n_m-1)} \sum_{i=1}^{n_m} \sum_{j=1}^{n_m} d_2(X_{m,i}, X_{m,j})^2$$

Donde n_m es el número de señales en el m -ésimo grupo.

Para evaluar la significancia del estadístico de prueba observado, realizamos un análisis de permutación. Esto implica:

- **Calcular el Estadístico de Prueba Observado:** Utilizamos la fórmula mencionada para calcular el valor del estadístico de prueba basado en los grupos formados originalmente.
- **Realizar Múltiples Permutaciones Aleatorias de las Etiquetas de Grupo:** Las etiquetas de grupo se reordenan aleatoriamente y se recalcula el estadístico de prueba utilizando las

mismas distancias precomputadas para cada permutación.

- **Calcular el Estadístico de Prueba para Cada Permutación:** Recalculamos el estadístico de prueba para cada permutación.
- **Contar las Permutaciones Donde el Nuevo Estadístico es Menor o Igual al Estadístico Observado:** El p-valor se obtiene como la proporción de permutaciones donde el nuevo estadístico es menor o igual al estadístico observado.

La implementación de este análisis permite determinar si las diferencias observadas entre los grupos formados por el mapper son estadísticamente significativas, lo cual nos permite identificar si los patrones topológicos extraídos difieren significativamente entre señales con y sin ondas gravitacionales. Por lo tanto, para que el p valor sea de utilidad, proponemos la siguiente prueba de hipótesis:

- H_0 : La sumatoria de las distancias de cada punto en la homología persistente de x grupo es igual al del grupo y . En otras palabras, **no hay diferencias significativas** en la topología de las señales entre diferentes niveles de coeficientes de escala de ruido.
- H_1 : La sumatoria de las distancias de cada punto en la homología persistente de x grupo **NO** es igual al del grupo y . En otras palabras, **hay diferencias significativas** en la topología de las señales entre diferentes niveles de coeficientes de escala de ruido.

Por lo tanto, como se desea comprobar que la clasificación del Mapper fue el correcto, lo que esperamos de nuestros resultados es que se rechace H_0 , lo que nos diría que efectivamente existen diferencias significativas entre los grupos que el Mapper clusterizó. En este caso consideramos que la zona de rechazo fue de $\alpha = 0.05$ para tener un nivel de confianza del 95% y asegurarnos de nuestros resultados.

7.1. Resultados:

Los resultados se muestran a continuación:

Distancia	Grupos	p-value
Euclideana	0.075 & 0.65	0.0384
Euclideana	0.362 & 0.65	0.0384
Euclideana	0.075 & 0.362	0.0384
Cuello de botella	0.075 & 0.65	0.0384
Cuello de botella	0.362 & 0.65	0.0384
Cuello de botella	0.075 & 0.362	0.0384

Table 3: Resultados estadístico de prueba

Observando la Tabla 7.1, vemos que en todos los casos tenemos un p valor de 0.0384, el cual es menor al nivel de significancia que es de 0.05. Por lo tanto, en todos los casos se rechaza H_0 de nuestra prueba de hipótesis, por consiguiente, podemos concluir con que la sumatoria de las distancias de cada punto en la homología persistente de x grupo **NO** es igual al del grupo y . En términos más sencillos, existen diferencias significativas en la topología de las señales entre diferentes niveles de coeficientes de escala de ruido, en este caso el valor de R .

Esto nos dice que el valor de R que es el radio de escala del ruido puede determinar si la red neuronal convolucional va a reconocer o no una onda gravitacional del ruido. En este caso, vemos que todos los grupos generados, los cuales son 3 grupos, cada grupo con una R diferente (0.075, 0.362 y 0.65), tienen diferencias significativas con todos los demás grupos, por lo tanto uno será más sencillo de reconocer que los otros. En este caso, concluimos que tener un valor de R más grande, facilitaría la detección de ondas gravitacionales debido a que el ruido se encuentra más esparcido, mientras que la onda gravitacional se encuentra más concentrado en su centro, por lo que la detección de patrones será más sencillo.

Comparando los resultados obtenidos por cada una de las distancias, se pudo observar que cada grupo fue tan diferente que, aún utilizando distintas distancias, llegó a la misma conclusión. Esto indica que las diferencias topológicas entre señales con diferentes niveles de coeficientes de escala de ruido son robustas y consistentes, independientemente de la métrica de distancia utilizada.

8. Conclusión

Las ondas gravitacionales son señales en las que hoy en día es un gran reto lograr detectarlas, sin embargo, estas pueden resultar de gran utilidad para entender más sobre nuestro universo y poder dar respuestas a grandes incógnitas que se tienen hoy en día en la humanidad. En esta investigación pudimos probar un gran método para facilitar y eficientar la manera en la que se detectan las ondas gravitacionales.

El uso del análisis topológico de datos (TDA) es una herramienta de gran utilidad para estos casos, en donde los datos están llenos de ruido y transformar los datos a espacios topológicos y en diferentes dimensiones puede ayudar a resolver nuestro problema. El uso combinado de la homología persistente con una red neuronal, nos ayuda a generar un modelo bastante favorable en estos casos, dándonos un resultado de hasta 74% de precisión.

El uso del Mapper también resultó ser de gran utilidad para este proyecto, el cual nos ayudó a clusterizar y entender características únicas de nuestra base de datos para así facilitar la detección de las ondas gravitacionales. En este caso, pudimos observar que entre mayor es el radio del ruido, mejor se podrán

identificar las ondas gravitacionales.

Sin duda todas estas herramientas nos ayuda a observar cosas más allá de lo que se pudiera analizar un método común y corriente, dándonos perspectivas más amplias y con más información la cual en este caso nos podría ayudar a contestar muchos de los misterios que se encuentran hoy en día sobre el universo.

9. Anexos

Link al código: Repositorio Github: Detección de ondas gravitacionales - Topología

REFERENCES

- [1] Datos sintéticos: ¿qué son y para qué se usan?, n.d. Retrieved May 24, 2024.
- [2] Jung J. Bresten, C. Detection of gravitational waves using topological data analysis and convolutional neural network: An improved approach. *arXiv preprint arXiv:1910.08245*, 2019.
- [3] ciberseg1922. ¿qué es epoch en machine learning?, December 15 2021. Ciberseguridad.
- [4] Harer J. Edelsbrunner, H. Persistent Homology, n.d.
- [5] F. Fuentes. Datos sintéticos: Impulso esencial para la ia. Blog de Arsys.es, August 2022.
- [6] W. Gragido, J. Pirc, N. Selby, and D. Molina. *Signal-to-Noise Ratio*. 2013.
- [7] Homología y Números de Betti - Repositorio Institucional de Documentos. Homología y números de betti - repositorio institucional de documentos, 2022. Unizar.es; Universidad de Zaragoza.
- [8] IBM. ¿qué son las redes neuronales convolucionales?, November 7 2023. Accessed: 2024-05-21.
- [9] icr.edit. ¿qué son los datos sintéticos y qué utilidades tienen? Icaria Technology, September 5 2023.
- [10] La Reducción de Dimensionalidad en el Machine Learning. La reducción de dimensionalidad en el machine learning, 2019. Softtek.com.
- [11] Parámetros e hiperparámetros en el Machine Learning — Codificando Bits. Parámetros e hiperparámetros en el machine learning — codificando bits, 2023. Codificando Bits.
- [12] VR Polygons. Vr polygons, 2018. Berkeley.edu.
- [13] What Is a Gravitational Wave? — NASA Space Place – NASA Science for Kids. What is a gravitational wave? — nasa space place – nasa science for kids, 2015. Nasa.gov.